Analiza efektywności kampanii marketingowej instytucji bankowej z wykorzystaniem modeli Uplift

Opracował:

Tomasz Michałowski

25 czerwca 2026

Spis treści

1 Wprowadzenie **2**

2 Cel analizy i uzasadnienie biznesowe **2**

3 Opis danych **2**
3.1 Struktura i jakość danych 3
3.2 Charakterystyka zmiennych 3

4 Weryfikacja randomizacji i równowagi grup **3**
4.1 Metodyka 3
4.2 Wyniki 4

5 Eksploracyjna analiza danych **4**
5.1 Rozkłady zmiennych i zależności między nimi 4
5.2 Współczynniki konwersji i heterogeniczność efektów kampanii 6

6 Metodologia **8**
6.1 Przygotowanie danych 8
6.2 Opis wybranych modeli 8

7 Ewaluacja modeli **9**
7.1 Metryki oceny 9
7.2 Wyniki porównania modeli 10
7.3 Krzywe uplift i sanity check 10
7.4 Krzywe ROC modeli bazowych 11
7.5 Stabilność i istotność statystyczna 11

8 Interpretacja modeli i analiza czynników wpływających na skuteczność kampanii **12**

9 Podsumowanie **14**

1 Wprowadzenie

Marketing bezpośredni stanowi jedno z podstawowych narzędzi pozyskiwania klientów w sektorze finansowym. W przypadku produktów takich jak lokaty terminowe banki regularnie prowadzą kampanie telefoniczne, których celem jest zwiększenie liczby nowych subskrypcji. Każdy kontakt z klientem generuje jednak określony koszt operacyjny związany z pracą konsultanta, infrastrukturą teleinformatyczną oraz organizacją kampanii. Z tego względu kluczowe znaczenie ma odpowiedni dobór odbiorców kampanii.

Tradycyjne podejście do targetowania opiera się na modelach klasyfikacyjnych przewidujących prawdopodobieństwo zakupu produktu. Modele takie pozwalają odpowiedzieć na pytanie, którzy klienci z największym prawdopodobieństwem dokonają zakupu. Nie oznacza to jednak, że kontakt marketingowy był przyczyną tej decyzji. Część klientów mogłaby bowiem dokonać zakupu niezależnie od kampanii, podczas gdy inni pozostaną niechętni produktowi bez względu na intensywność działań marketingowych.

Z punktu widzenia biznesu znacznie bardziej wartościowa jest odpowiedź na pytanie:

Którzy klienci dokonają zakupu właśnie dzięki kontaktowi marketingowemu?

Odpowiedź na to pytanie dostarcza modelowanie uplift, będące jednym z zastosowań metod inferencji przyczynowej. W odróżnieniu od klasycznej analizy grupowej, która wyznacza średni efekt kampanii dla całej populacji, modelowanie uplift szacuje heterogeniczny efekt przyczynowy na poziomie pojedynczego klienta — pozwala więc określić, dla kogo kontakt marketingowy generuje największy przyrost prawdopodobieństwa zakupu. Końcowym rezultatem jest ranking klientów umożliwiający porównanie oczekiwanego efektu kampanii opartej na modelu z dotychczasowym podejściem opartym na losowym doborze odbiorców.

2 Cel analizy i uzasadnienie biznesowe

Celem projektu było opracowanie proof of concept umożliwiającego optymalizację kolejnej fali kampanii marketingowej banku. Zadanie polegało na wykorzystaniu danych historycznych z poprzedniej kampanii telefonicznej do zbudowania modeli szacujących indywidualny efekt kontaktu marketingowego dla każdego klienta oraz ilościowego porównania oczekiwanego efektu kampanii opartej na modelu z dotychczasowym podejściem opartym na losowym doborze odbiorców. Uzasadnieniem dla tego podejścia jest fundamentalna słabość klasycznych modeli klasyfikacyjnych stosowanych w targetowaniu kampanii. Modele te wskazują klientów o najwyższym prawdopodobieństwie zakupu, nie odpowiadają jednak na pytanie, czy to właśnie kontakt marketingowy był przyczyną tej decyzji. W praktyce populację klientów można podzielić na cztery grupy: Sure Things — osoby, które dokonają zakupu niezależnie od kampanii; Lost Causes — osoby, które nie kupią produktu nawet po kontakcie; Persuadables — osoby, których decyzja jest bezpośrednim efektem działań marketingowych; oraz Sleeping Dogs — osoby, u których kontakt marketingowy obniża prawdopodobieństwo zakupu. Klasyczny model klasyfikacyjny koncentruje zasoby głównie na grupie Sure Things, generując koszty bez dodatkowej wartości biznesowej. Celem modelowania uplift jest natomiast identyfikacja grupy Persuadables i skierowanie do niej możliwie największej części budżetu kampanii.

3 Opis danych

Do realizacji projektu wykorzystano zbiór danych pochodzący z kampanii marketingowej portugalskiego banku, której celem było pozyskanie klientów zainteresowanych lokatą terminową. Zbiór zawierał 41 188 obserwacji oraz 22 zmienne opisujące cechy klientów, historię wcześniejszych kontaktów marketingowych oraz wskaźniki makroekonomiczne.

3.1 Struktura i jakość danych

Zbiór zawierał dwie zmienne kluczowe dla modelowania uplift: `test_control_flag` — flaga przypisania do grupy eksperymentalnej lub kontrolnej (zmienna treatment), oraz `y` — target binarny informujący o zakupie lokaty terminowej. Rozkład klientów pomiędzy grupami był nierówny — 24 712 obserwacji w grupie kontrolnej (około 60%) i 16 476 w grupie kampanii (około 40%) — jednak wystarczający do wiarygodnej estymacji efektów kampanii.

W zbiorze zidentyfikowano 2 306 zduplikowanych rekordów (5,6% obserwacji) oraz niewielki odsetek braków danych dla zmiennej `cons.price.idx` (około 0,6%). Największy udział braków dotyczył zmiennych opisujących przebieg bieżącej kampanii — `contact`, `month`, `day_of_week`, `duration` oraz `campaign` — gdzie brakowało około 60% wartości. Nie wynikało to z błędów w danych, lecz z konstrukcji eksperymentu: klienci z grupy kontrolnej nie byli kontaktowani, więc informacje o przebiegu rozmowy telefonicznej nie mogły zostać zarejestrowane.

Zmienne `duration` oraz `campaign` zostały wykluczone z modelowania ze względu na ryzyko data leakage — opisują przebieg kampanii i są dostępne dopiero po wykonaniu kontaktu, a więc nie mogą być wykorzystane do podejmowania decyzji o targetowaniu przyszłych kampanii.

3.2 Charakterystyka zmiennych

Zbiór zawierał cztery grupy zmiennych. Cechy demograficzne klientów obejmowały wiek, zawód, stan cywilny, poziom wykształcenia oraz informacje o zadłużeniu i kredytach. Druga grupa opisywała historię wcześniejszych kontaktów marketingowych — wynik poprzednich kampanii (`poutcome`), liczbę wcześniejszych kontaktów (`previous`) oraz liczbę dni od ostatniego kontaktu (`pdays`). Trzecią grupę stanowiły wskaźniki makroekonomiczne: stopa Euribor, wskaźnik zatrudnienia, indeks cen konsumenckich oraz wskaźnik nastrojów konsumenckich. Czwartą grupę tworzyły zmienne opisujące przebieg bieżącej kampanii — kanał kontaktu (`contact`), miesiąc i dzień tygodnia kontaktu oraz czas trwania i liczba wykonanych połączeń. Zmienne tej grupy zostały wykluczone z modelowania: `duration` i `campaign` ze względu na data leakage, pozostałe zaś dlatego że nie będą dostępne na etapie scoringu przyszłej kampanii.

4 Weryfikacja randomizacji i równowagi grup

Przed przystąpieniem do modelowania zweryfikowano, czy podział klientów na grupę kontrolną i eksperymentalną został przeprowadzony poprawnie. W modelowaniu uplift jest to krok kluczowy — tylko przy porównywalnych grupach różnice w konwersji można przypisać kampanii, a nie wcześniejszym różnicom między klientami. Zastosowany układ eksperymentalny, w którym obie grupy zostały dobrane losowo przed rozpoczęciem kampanii, odpowiada schematowi Randomized Controlled Trial.

4.1 Metodyka

Dla zmiennych numerycznych zastosowano test Welcha (t-test dla prób niezależnych bez założenia równości wariancji) oraz Standardized Mean Difference (SMD), obliczone jako:

$$SMD = \frac{\bar{x}_T - \bar{x}_C}{s_{pooled}}$$

gdzie s_{pooled} oznacza odchylenie standardowe obliczone na całej próbie łącznie. Za kryterium równowagi przyjęto $|SMD| < 0.1$ oraz $p > 0.05$. Dla zmiennych kategorycznych zastosowano test niezależności χ^2.

4.2 Wyniki

Tabela 1: Balance check dla zmiennych numerycznych

Zmienna	SMD	p-value
age	−0.0058	0.5664
cons.conf.idx	−0.0101	0.3150
cons.price.idx	−0.0078	0.4363
emp.var.rate	−0.0039	0.7016
euribor3m	−0.0050	0.6184
nr.employed	−0.0037	0.7102
pdays	0.0027	0.7869
previous	−0.0010	0.9231

Dla wszystkich analizowanych zmiennych wartości SMD były bliskie zeru, a p-value znacząco przekraczały poziom istotności 0.05. Zmienne `duration` i `campaign` zostały wyłączone z balance check — dla klientów z grupy kontrolnej nie istnieją żadne obserwacje tych zmiennych (brak kontaktu), co uniemożliwia przeprowadzenie testu. Ich niezbalansowanie wynika wprost z konstrukcji eksperymentu, a nie z błędów randomizacji.

Dla wszystkich zmiennych kategorycznych (`job`, `marital`, `education`, `default`, `housing`, `loan`, `poutcome`) test χ^2 nie wykazał istotnych różnic między grupami (wszystkie $p > 0.05$).

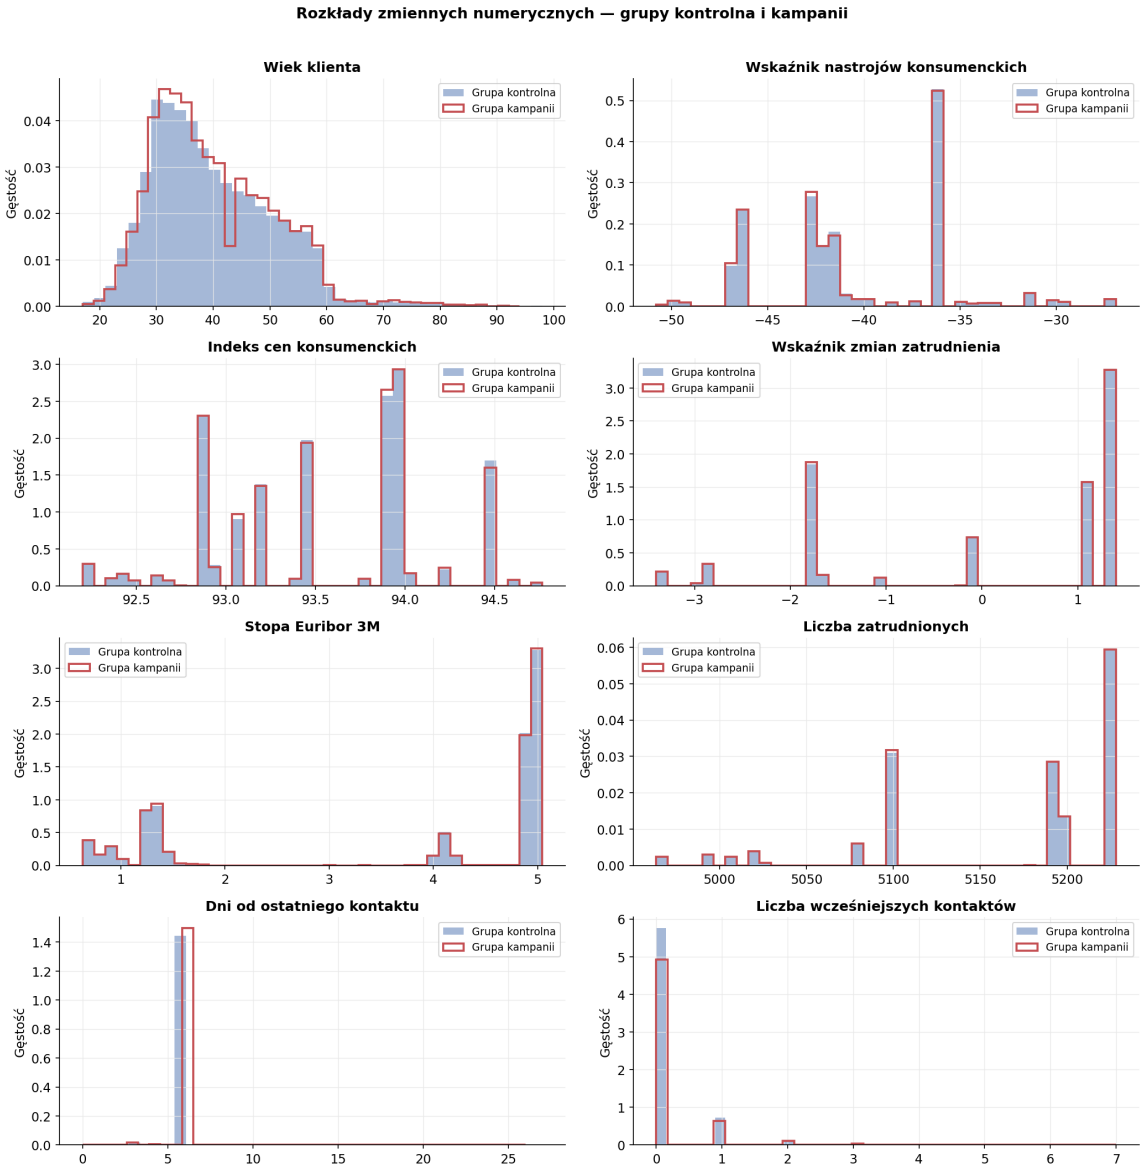
Przeprowadzona analiza potwierdza poprawność randomizacji — obie grupy były przed kampanią statystycznie porównywalne pod względem cech demograficznych, historii kontaktów oraz wskaźników makroekonomicznych. Zaobserwowane później różnice w poziomie konwersji ($CR_{treatment}$ = 15.08% vs $CR_{control}$ = 10.86%, raw lift = +4.22%) mogą być interpretowane jako efekt przyczynowy kampanii marketingowej.

5 Eksploracyjna analiza danych

Eksploracyjna analiza danych w kontekście modelowania uplift służy nie tylko ocenie jakości danych, lecz przede wszystkim weryfikacji heterogeniczności efektów kampanii między segmentami klientów. Jednorodna populacja nie daje podstaw do budowy modelu uplift — wartość takiego podejścia pojawia się dopiero wtedy, gdy reakcja klientów na działania marketingowe jest zróżnicowana i przewidywalna na podstawie dostępnych cech. Analiza objęła rozkłady zmiennych numerycznych, macierz korelacji oraz współczynniki konwersji dla zmiennych kategorycznych.

5.1 Rozkłady zmiennych i zależności między nimi

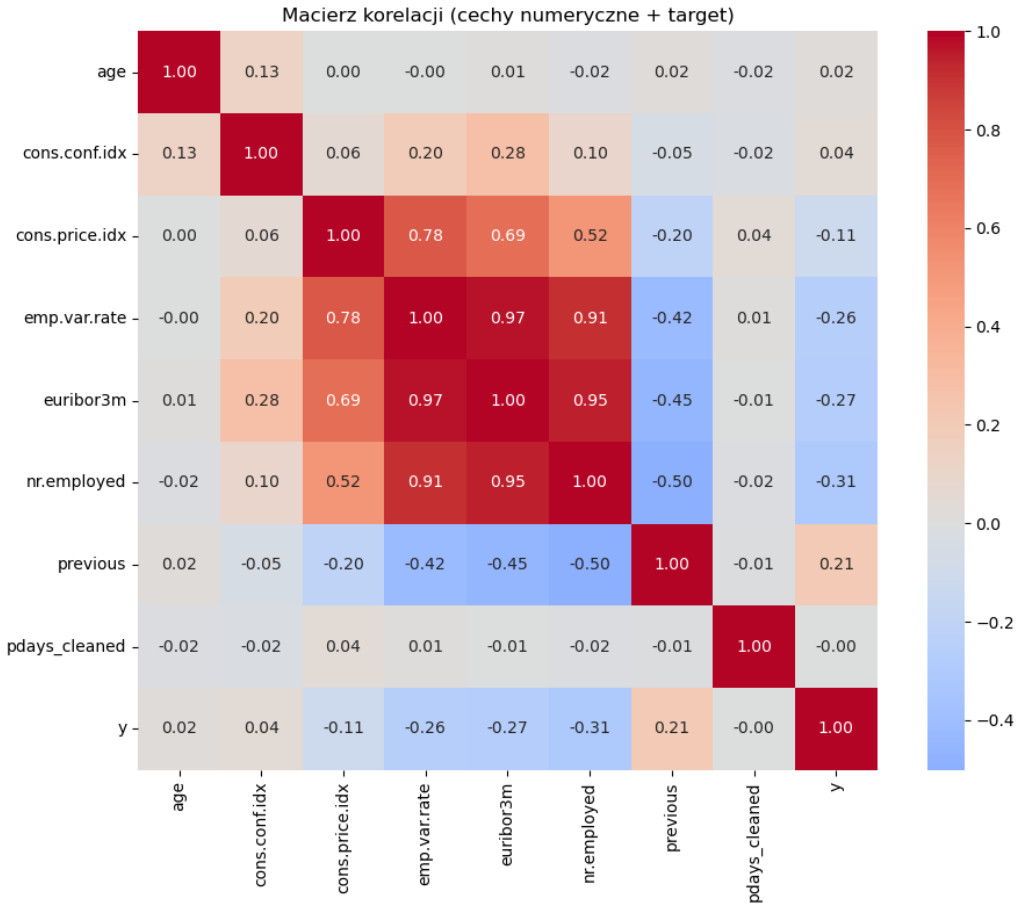
Rozkłady zmiennych numerycznych przedstawiono na rysunku 1. Wiek klientów koncentruje się w przedziale 25–50 lat z umiarkowaną asymetrią prawostronną. Zmienne makroekonomiczne — stopa Euribor, wskaźnik zatrudnienia oraz indeks cen konsumenckich — przyjmują wartości skupione wokół kilku poziomów, co odzwierciedla kwartalną lub miesięczną częstotliwość ich aktualizacji. Zmienna `previous` wykazuje silną asymetrię prawostronną — większość klientów nie miała wcześniejszych kontaktów z bankiem.



Rysunek 1: Rozkłady zmiennych numerycznych w grupach kontrolnej i kampanii

Rozkłady w obu grupach są niemal identyczne dla wszystkich zmiennych, co stanowi wizualne potwierdzenie poprawności randomizacji wykazanej w poprzedniej sekcji.

Macierz korelacji (rysunek 2) ujawnia silne współliniowości między wskaźnikami makroekonomicznymi — `euribor3m`, `emp.var.rate` oraz `nr.employed` są ze sobą skorelowane na poziomie 0.91–0.97. Oznacza to, że niosą w dużej mierze tę samą informację o cyklu koniunkturalnym. Dla modeli drzewiastych (XGBoost, LightGBM) nie stanowi to problemu, natomiast zostało uwzględnione przy interpretacji wyników regresji logistycznej. Korelacje zmiennych demograficznych z targetem są niskie, co sugeruje że sama przynależność do grupy demograficznej słabo przewiduje zakup — istotniejszy jest kontekst makroekonomiczny i historia wcześniejszych kontaktów.



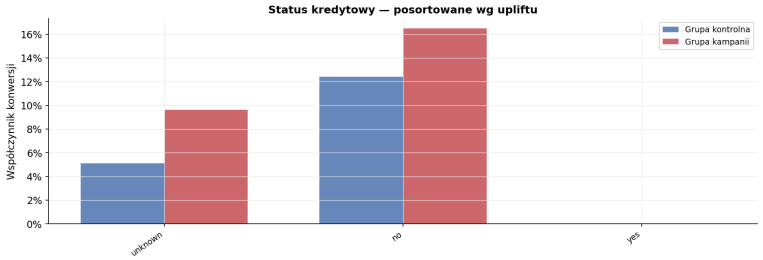
Rysunek 2: Macierz korelacji zmiennych numerycznych

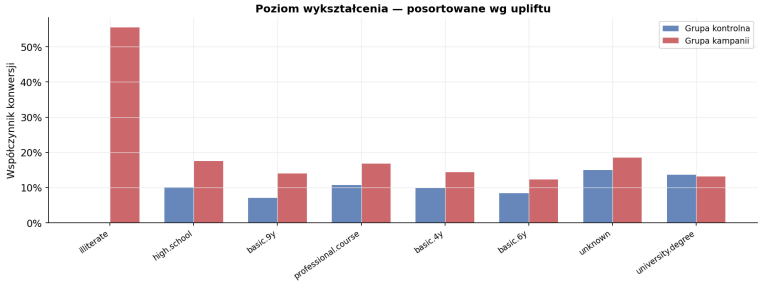
5.2 Współczynniki konwersji i heterogeniczność efektów kampanii

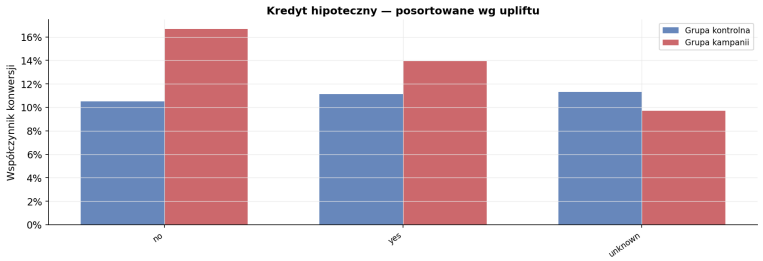
Ogólny współczynnik konwersji wyniósł 12.55%, przy czym grupa kampanii osiągnęła CR na poziomie 15.08% wobec 10.86% w grupie kontrolnej. Surowy lift kampanii wynosi zatem +4.22 p.p. i stanowi punkt odniesienia dla oceny modeli uplift.

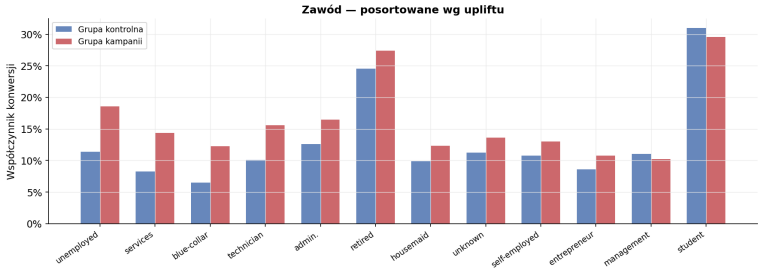
Analiza współczynników konwersji dla zmiennych kategorycznych (rysunek 3) wskazuje na istotne zróżnicowanie efektów kampanii między segmentami klientów. Największy uplift obserwowany jest wśród osób stanu wolnego (+8.1 p.p.), klientów bez kredytu hipotecznego (+6.1 p.p.) oraz osób bezrobotnych (+7.2 p.p.). Interesującym wyjątkiem są klienci z pozytywnym wynikiem poprzedniej kampanii (`poutcome = success`) — ich CR w grupie kontrolnej wynosi aż 64%, co oznacza że kupują lokatę niezależnie od kampanii i reprezentują grupę Sure Things, dla której dodatkowy kontakt marketingowy nie generuje wartości. Zróżnicowanie to potwierdza zasadność modelowania uplift — efekt kampanii jest silnie heterogeniczny i wymaga indywidualnej estymacji na poziomie klienta.

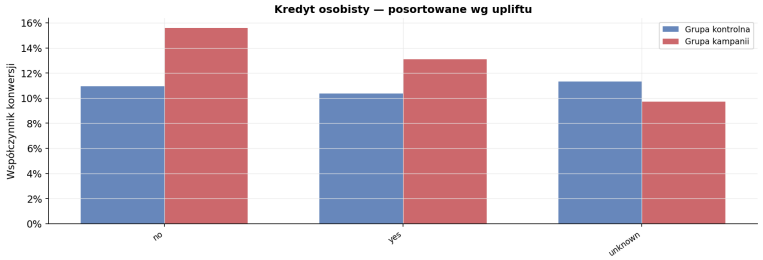
Współczynniki konwersji dla zmiennych kategorycznych

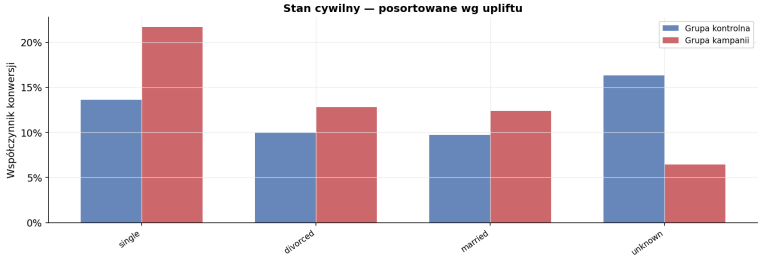


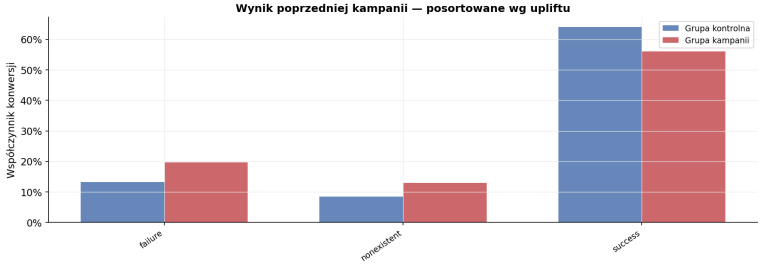












6 Metodologia

6.1 Przygotowanie danych

Proces przygotowania danych skoncentrowano na eliminacji ryzyka data leakage oraz zachowaniu wyłącznie informacji dostępnych przed rozpoczęciem kampanii marketingowej. Usunięto zmienne `duration` i `campaign` opisujące przebieg bieżącej kampanii, niedostępne na etapie scoringu przyszłych klientów, oraz `test_control_flag` zakodowaną jako binarna zmienna treatment W.

Zmienna `pdays` wymagała osobnej obsługi ze względu na dominującą wartość 999 oznaczającą brak wcześniejszego kontaktu. Zastąpiono ją dwoma cechami: flagą binarną `was_contacted_before` oraz `pdays_cleaned`, w której wartość 999 zastąpiono medianą obliczoną na podzbiorze klientów z historią kontaktu (mediana = 6 dni).

Zmienne kategoryczne zakodowano metodą One-Hot Encoding, a dla zmiennych numerycznych zastosowano imputację medianą oraz standaryzację. Preprocessing został dopasowany wyłącznie na zbiorze treningowym i następnie zastosowany do zbiorów walidacyjnego i testowego, co eliminuje ryzyko wycieku informacji między zbiorami.

Dane podzielono na zbiory treningowy (60%), walidacyjny (20%) i testowy (20%) z stratyfikacją po czterech kombinacjach zmiennych $y \times W$, co zapewnia zachowanie proporcji grup i współczynników konwersji we wszystkich podzbiorach. Po podziale zbiór treningowy zawierał 24 712 obserwacji, walidacyjny i testowy po 8 238.

Ponieważ dane pochodzą z eksperymentu RCT z potwierdzonym balance checkiem, wagi IPW zastosowano jako dodatkową warstwę ostrożności korygującą niezbalansowanie proporcji grup (60% kontrolna, 40% kampanii), a nie jako korektę braków randomizacji.

6.2 Opis wybranych modeli

Celem modelowania było oszacowanie indywidualnego efektu przyczynowego kampanii dla każdego klienta:

$$\tau(x) = P(Y = 1 \mid T = 1, X = x) - P(Y = 1 \mid T = 0, X = x)$$

Dodatnia wartość $\tau(x)$ oznacza, że kampania zwiększa prawdopodobieństwo zakupu dla danego klienta, ujemna, że kontakt marketingowy może działać odwrotnie do zamierzonego. Porównano cztery podejścia do estymacji $\tau(x)$.

T-Learner należy do grupy meta-learnerów i trenuje dwa niezależne modele $\hat{\mu}_1(x)$ na podzbiorze klientów z grupy kampanii i $\hat{\mu}_0(x)$ na podzbiorze grupy kontrolnej. Uplift wyznaczany jest jako różnica predykcji obu modeli dla każdego klienta. Kluczową zaletą tego podejścia jest możliwość niezależnego uchwycenia zależności charakterystycznych dla każdej grupy model $\hat{\mu}_1(x)$ może nauczyć się wzorców specyficznych dla klientów reagujących na kampanię, podczas gdy $\hat{\mu}_0(x)$ modeluje naturalne zachowania zakupowe niezależne od marketingu. Wadą jest potencjalna niestabilność przy małych zbiorach danych, gdy jeden z modeli jest uczony na niewielkiej próbie. W projekcie zastosowano trzy warianty modelu bazowego: regresję logistyczną (LR), XGBoost oraz LightGBM, co pozwala ocenić czy złożoność modelu bazowego przekłada się na jakość estymacji upliftu.

Regresja logistyczna stanowi punkt odniesienia, model liniowy o wysokiej interpretowalności, zakładający liniową zależność między cechami a logarytmem ilorazu szans. XGBoost i LightGBM to algorytmy gradient boosting budujące model jako sumę kolejnych drzew decyzyjnych, zdolne do modelowania nieliniowości i interakcji między zmiennymi. LightGBM stosuje strategię leaf-

wise growth, która w praktyce prowadzi do krótszego czasu uczenia przy porównywalnej jakości predykcji.

S-Learner wykorzystuje pojedynczy model uczony jednocześnie na obu grupach, z W jako dodatkową cechą wejściową. Uplift wyznaczany jest przez dwukrotną predykcję counterfactual — raz z $W = 1$ i raz z $W = 0$ — dla każdego klienta, a różnica tych predykcji stanowi oszacowanie efektu przyczynowego. Podejście to pozwala modelowi bezpośrednio uchwycić interakcje między cechami klienta a zmienną treatment. Głównym ograniczeniem S-Learnera jest tendencja do niedoszacowywania efektów przyczynowych, gdy wpływ kampanii jest relatywnie słaby względem pozostałych zmiennych, model może traktować W jako mało istotną cechę i przypisywać jej niski wpływ na predykcję. Zastosowano XGBoost jako model bazowy.

Causal Forest DML to wyspecjalizowana metoda inferencji przyczynowej estymująca efekt kampanii bezpośrednio, bez konieczności modelowania odrębnych potencjalnych wyników. Algorytm działa w dwóch etapach: w pierwszym buduje modele pierwszego stopnia przewidujące Y i T na podstawie cech X, a w drugim estymuje efekt przyczynowy na residuach z obu modeli, eliminując w ten sposób wpływ confounders przez partialling-out. Drzewa w lesie są budowane tak, aby maksymalizować heterogeniczność efektów między segmentami klientów, a nie minimalizować błąd predykcji zmiennej wynikowej. Las składał się z 1 000 drzew z ograniczeniem `min_samples_leaf=50` dla stabilności estymacji oraz pięciokrotną walidacją krzyżową w procedurze DML.

Class Variable Transformation (CVT) przekształca problem uplift w klasyczne zadanie klasyfikacyjne przez zdefiniowanie nowej zmiennej $Z = \mathbf{1}[(W = 1 \wedge Y = 1) \vee (W = 0 \wedge Y = 0)]$. Intuicja stojąca za tą transformacją jest następująca: klient należący do grupy kampanii który kupił produkt oraz klient z grupy kontrolnej który nie kupił — obaj są przykładami obserwacji gdzie przynależność grupowa i wynik są zgodne, co odpowiada klientom podatnym na kampanię. Metoda została zaimplementowana z LightGBM jako modelem bazowym, jednak ze względu na bardzo wysoką wariancję predykcji na zbiorze walidacyjnym (std = 0.76, wobec 0.08–0.23 dla pozostałych modeli) została wykluczona z finalnego porównania jako niestabilna w tym zastosowaniu.

7 Ewaluacja modeli

7.1 Metryki oceny

Ocena jakości modeli uplift wymaga innych miar niż klasyczna klasyfikacja. Tradycyjne metryki takie jak AUC ROC oceniają zdolność przewidywania zdarzenia, nie pozwalają jednak ocenić jakości estymacji efektu przyczynowego. W projekcie zastosowano metrykę Qini Score (implementacja `qini_auc_score` z biblioteki `scikit-uplift`), będącą odpowiednikiem AUC dla krzywych uplift. Miara ta ocenia jak skutecznie model rankinguje klientów według przewidywanego efektu kampanii, im wyższa wartość, tym więcej incremental conversions model koncentruje wśród klientów kontaktowanych jako pierwsi.

Krzywa Qini konstruowana jest przez sortowanie klientów malejąco według przewidywanego upliftu i śledzenie skumulowanej liczby dodatkowych konwersji generowanych przez kampanię względem linii losowego targetowania. Model idealny koncentruje wszystkich Persuadables na początku rankingu, generując stromą krzywą daleko powyżej linii losowej. Pole powierzchni pod tą krzywą stanowi Qini Score.

Dodatkowo przeprowadzono:

- ocenę krzywych ROC dla modeli bazowych T-Learnera,

- bootstrapową analizę stabilności Qini Score (1 000 resampli) z wyznaczeniem 95% przedziału ufności,
- placebo test — predykcje modelu zestawiono z losowo permutowanymi etykietami W, rozrywając związek między rankingiem a rzeczywistym przypisaniem do grup. Spadek Qini Score do wartości bliskich zeru potwierdza że model rankinguje klientów na podstawie efektu kampanii, a nie ogólnego prawdopodobieństwa zakupu.

7.2 Wyniki porównania modeli

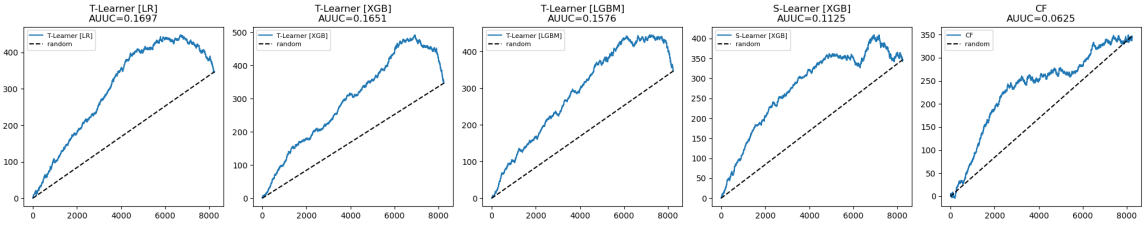
Tabela 2 przedstawia wyniki wszystkich modeli na zbiorze testowym.

Tabela 2: Porównanie modeli uplift na zbiorze testowym

Model	Qini Score	Średni uplift
T-Learner (LR)	0.20833	−0.0229
T-Learner (LGBM)	0.17896	+0.0647
T-Learner (XGB)	0.17758	+0.0601
S-Learner (XGB)	0.14392	+0.0840
Causal Forest	0.09262	+0.0463

Najwyższy Qini Score osiągnął T-Learner z regresją logistyczną (0.208), wyprzedzając modele boostingowe oraz Causal Forest. Prostszy model liniowy okazał się skuteczniejszy w rankingowaniu klientów według efektu przyczynowego niż bardziej zaawansowane metody. Możliwą przyczyną jest charakter efektów kampanii w tym zbiorze danych: jeśli heterogeniczność upliftu jest w dużej mierze liniowa względem dostępnych cech, modele nieliniowe nie wnoszą dodatkowej wartości, a ich większa wariancja może obniżać jakość rankingu. Warto odnotować że T-Learner (LR) osiąga ujemny średni uplift (-0.023), wynika to z faktu że regresja logistyczna z regularyzacją ($C = 0.1$) silnie ściąga predykcje ku średniej, przez co różnica $\hat{\mu}_1(x) - \hat{\mu}_0(x)$ może być ujemna dla wielu obserwacji. Nie wpływa to jednak na jakość rankingu mierzoną Qini Score.

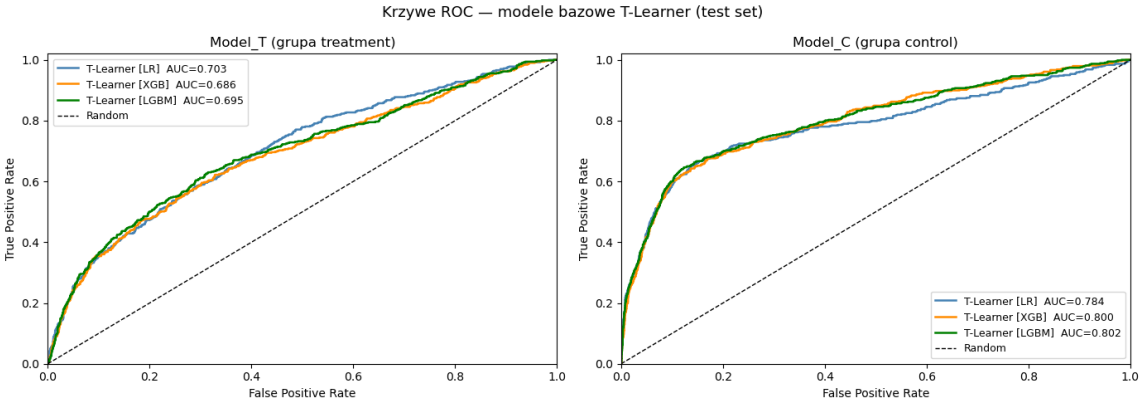
7.3 Krzywe uplift i sanity check



Rysunek 4: Krzywe uplift dla wszystkich modeli na zbiorze walidacyjnym

Rysunek 4 przedstawia krzywe uplift dla wszystkich modeli. Prawidłowo działający model powinien generować krzywą powyżej linii losowej. Klienci z najwyższym przewidywanym uplift powinni rzeczywiście wykazywać wyższy efekt kampanii. Wszystkie modele spełniają ten warunek.

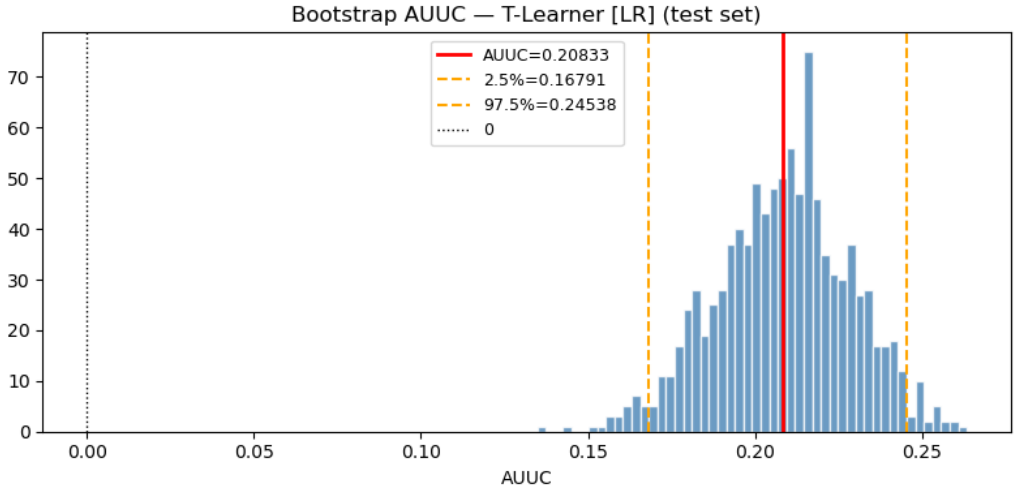
7.4 Krzywe ROC modeli bazowych



Rysunek 5: Krzywe ROC modeli bazowych T-Learnera na zbiorze testowym

Rysunek 5 przedstawia krzywe ROC dla modeli bazowych $\hat{\mu}_1(x)$ (grupa kampanii) i $\hat{\mu}_0(x)$ (grupa kontrolna). Modele boostingowe osiągają wyższe AUC niż regresja logistyczna. XGBoost i LightGBM lepiej przewidują samo prawdopodobieństwo zakupu. Fakt że gorszy predyktor zakupu (LR) daje lepszy model uplift potwierdza kluczową obserwację: optymalizacja pod kątem klasyfikacji nie jest równoznaczna z optymalizacją pod kątem efektu przyczynowego.

7.5 Stabilność i istotność statystyczna



Rysunek 6: Bootstrapowa analiza stabilności Qini Score — T-Learner (LR), zbiór testowy

Bootstrapowa analiza (1 000 resampli) wykazała że Qini Score T-Learnera (LR) wynosi 0.208 z 95% przedziałem ufności [0.168, 0.245]. Cały przedział jest dodatni, co potwierdza istotność statystyczną wyników. Wyniki placebo testu przedstawiono w tabeli 3 — dla wszystkich modeli Qini Score po permutacji etykiet W spada do wartości bliskich zeru, co potwierdza że modele rankingują klientów na podstawie rzeczywistego efektu kampanii, a nie ogólnego prawdopodobieństwa zakupu.

Tabela 3: Wyniki placebo testu — porównanie rzeczywistego Qini Score z wartością uzyskaną dla permutowanych etykiet W

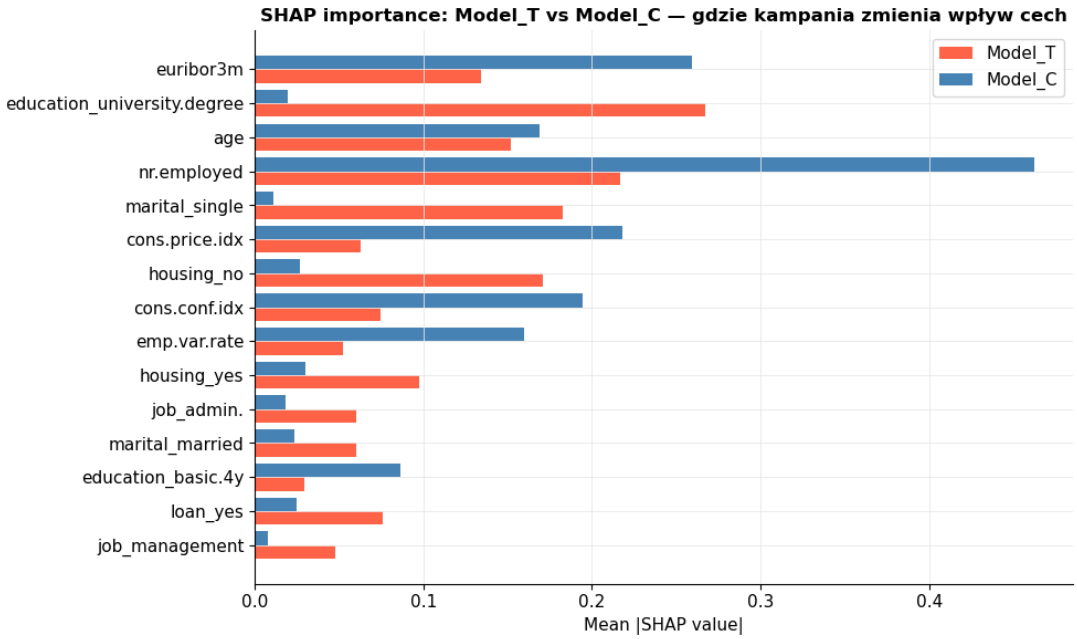
Model	Qini Score	Qini Score (placebo)
T-Learner (LR)	0.20833	0.00142
T-Learner (LGBM)	0.17896	0.00039
T-Learner (XGB)	0.17758	−0.00164
S-Learner (XGB)	0.14392	0.00228
Causal Forest	0.09262	−0.00285

Dla wszystkich modeli Qini Score po permutacji etykiet W spada praktycznie do zera, podczas gdy rzeczywiste wartości mieszczą się w przedziale 0.09–0.21. Różnica rzędu dwóch rzędów wielkości potwierdza że modele uczą się efektu kampanii, a nie przypadkowych wzorców w danych.

8 Interpretacja modeli i analiza czynników wpływających na skuteczność kampanii

Sama informacja o jakości rankingu nie jest wystarczająca z punktu widzenia biznesowego. Równie istotne jest zrozumienie, które cechy klientów decydują o tym, że kampania jest dla nich skuteczna. W tym celu zastosowano metodę SHAP (SHapley Additive Explanations), która przypisuje każdej zmiennej wartość odpowiadającą jej marginalnemu wkładowi do predykcji modelu. Analizę przeprowadzono na modelach bazowych T-Learnera z LightGBM — $\hat{\mu}_1(x)$ dla grupy kampanii i $\hat{\mu}_0(x)$ dla grupy kontrolnej — na losowej próbie 1 000 obserwacji ze zbioru testowego.

Kluczową miarą w kontekście uplift modeling jest różnica wartości SHAP między oboma modelami: $|\text{SHAP}_T| - |\text{SHAP}_C|$. Zmienna o wysokiej różnicy wpływa silnie na predykcję w jednej grupie, ale słabo w drugiej — oznacza to że kampania zmienia sposób w jaki ta cecha oddziałuje na decyzję zakupową klienta. To właśnie te zmienne są najbardziej informatywne przy identyfikacji grupy Persuadables.



Rysunek 7: Różnica wartości SHAP między modelem kampanii i kontrolnym — cechy o największym wpływie na heterogeniczność efektu kampanii

Rysunek 7 przedstawia 15 cech o największej różnicy wartości SHAP między grupami. Najsilniejszy efekt heterogeniczny obserwowany jest dla stopy Euribor (`euribor3m`, różnica SHAP: 0.292) oraz poziomu wykształcenia wyższego (`education_university.degree`, 0.277). Oznacza to że otoczenie makroekonomiczne oraz profil wykształcenia klienta w różny sposób wpływają na decyzję zakupową w grupie kampanii i grupie kontrolnej — kampania zmienia wagę tych cech w procesie decyzyjnym. Wysoka pozycja `nr.employed` (0.247) oraz `cons.price.idx` (0.172) wskazuje że kontekst rynku pracy i inflacji również modyfikuje skuteczność kampanii.

Wiek klienta (`age`, różnica SHAP: 0.253) zajmuje trzecią pozycję, co sugeruje że podatność na kampanię jest silnie zróżnicowana wiekowo. Stan cywilny — konkretnie bycie osobą stanu wolnego (`marital_single`, 0.187) — zwiększa responsywność na kampanię, co jest spójne z wynikami EDA gdzie single osiągali uplift +8.1 p.p. wobec średniej +4.2 p.p.

Z perspektywy biznesowej profil klienta najbardziej responsywnego na kampanię obejmuje osoby z wyższym wykształceniem, stanu wolnego, bez kredytu hipotecznego, kontaktowane w okresach wyższych stóp procentowych Euribor.

9 Podsumowanie

Celem przeprowadzonego badania było opracowanie modelu umożliwiającego optymalizację targetowania kolejnej fali kampanii marketingowej banku z wykorzystaniem metod modelowania uplift. W przeciwieństwie do klasycznych modeli klasyfikacyjnych, które wskazują klientów o najwyższym prawdopodobieństwie zakupu, zastosowane podejście koncentruje się na identyfikacji klientów dla których kontakt marketingowy generuje największy przyrostowy efekt — grupy Persuadables.

Przeprowadzona analiza obejmowała pełny proces: weryfikację poprawności randomizacji, eksploracyjną analizę danych, przygotowanie cech, budowę i porównanie pięciu modeli uplift oraz interpretację wyników metodą SHAP. Spośród porównanych podejść — T-Learner z regresją logistyczną, XGBoost i LightGBM, S-Learner z XGBoost oraz Causal Forest DML — najlepsze wyniki osiągnął T-Learner z regresją logistyczną, uzyskując Qini Score równy 0.208 na zbiorze testowym z 95% przedziałem ufności [0.168, 0.245]. Fakt że prostszy model liniowy przewyższył bardziej zaawansowane metody sugeruje że heterogeniczność efektów kampanii w tym zbiorze danych ma w dużej mierze liniowy charakter.

Kluczowym wynikiem biznesowym jest kwantyfikacja przewagi modelu nad losowym targetowaniem. Surowy lift kampanii wynosi +4.22 p.p. ($CR_{treatment}$ = 15.08% vs $CR_{control}$ = 10.86%). Koncentrując kampanię na top 30% klientów według rankingu modelu, uzyskuje się uplift na poziomie +11.1 p.p. — ponad dwukrotnie wyższy niż przy losowym doborze odbiorców. Matematyczne optimum modelu wskazuje na targetowanie około 51% bazy klientów, przy którym model generuje 127.9 dodatkowych konwersji więcej niż losowa selekcja przy tym samym zasięgu kampanii.

Analiza SHAP wykazała że efektywność kampanii jest najsilniej zróżnicowana ze względu na otoczenie makroekonomiczne (stopa Euribor, wskaźnik zatrudnienia), poziom wykształcenia oraz wiek klienta. Profil klienta najbardziej responsywnego na kampanię obejmuje osoby z wyższym wykształceniem, stanu wolnego oraz bez kredytu hipotecznego, kontaktowane w okresach wyższych stóp procentowych.

Praktycznym rezultatem analizy jest ranking klientów według przewidywanego wpływu kampanii (uplift), który umożliwia bardziej efektywną alokację budżetu marketingowego. Zamiast kierować działania do losowo wybranej grupy odbiorców, bank może skoncentrować zasoby na klientach o najwyższym potencjale wzrostu prawdopodobieństwa konwersji. Takie podejście pozwala zmaksymalizować liczbę konwersji inkrementalnych przy niezmienionym lub nawet niższym koszcie kampanii, zwiększając tym samym jej efektywność oraz zwrot z inwestycji marketingowych.